

第2章

既往研究の整理

2.1 諸言

本章では、各個人の活動需要を予測生成する Activity-based Model(ABM) 及び提案手法に使われる機械学習理論について、手法と利用動向を整理し、本研究の位置付けを行う。

本研究では、複数の計算要素の相互関係を、ABM の体系の中でデータ駆動に反映し、施策検討の際にも考慮が可能な ABM の開発を目標とする。そのためには、既存の ABM が採用している活動需要の生成方法とデータ同化の手法のプログラムの中に、計算要素の相互関係を反映するための機能を内装する必要がある。そのため、初めに 2.1 節で ABM について整理した後、2.2 節以降で計算要素の相互関係を記述、推定する手法についてレビューを行う。

2.2 節で取り上げるグラフィカルモデルは、変数間の関係をグラフの形で記述する機械学習モデルであり、グラフ構造を推定することで解釈性や確率計算の速度の面で優れたモデルを構築できる。本モデルは ABM でも近年多く採用されており、変数間の関係を明示的に学習することに成功していることから、本研究の目的に合致しつつ利用可能性の高いモデルとしてレビューを行う。

2.2 Activity-based Model

Activity-based Model(ABM) は、活動の派生需要として移動を捉え、予測・生成するモデルである。交通の需要、配分分析として使われていた四段階推定の限界を克服するものとして研究が始まり、MATSim(Balmer et al., 200) をはじめとして活動需要の生成から経路への配分まで全てを含むモデルも多く開発されている (Rasouli & Timmermans, 2014)。一方、研究の中ではモデル改善のため、活動需要を生成するためのモデルを独立して捉えることが多く、近年でも既存 ABM の枠組みに新しく開発した活動需要モデルを組み込む研究も多く見られる。本節では活動需要を生成する ABM について、その計算方法と利用法のレビューを行う。

2.2.1 モデル分類と計算手法

活動需要を生成する ABM は、その計算方法に基づいて主に 3 つの分類に区分される。近年ではこれらに加え、機械学習分野のモデルを生成モデルとして用いることで個人の活動需要を生成する研究が現れている。各分類の主な論文とモデルを表 2-1 に示す。

1. 計算プロセス型モデル

2. 離散選択型モデル
3. 制約ベースモデル
4. 機械学習分野モデル

一方, Tajaddini et al.(2020) が言及するように, 往年の3つの ABM は計算プロセス型のヒューリスティクスと離散選択型の確率モデルを組み合わせる形で構成されていることが多いことに注意したい. 表 2.1 に, ABM の主な計算要素の計算方法として, 本表の枠に当てはまる ABM が, どの種類を採用しているかを示す. ALBATROSS(Arentze & Timmermans, 2004) が計算プロセス型, Bowman & Ben-Akiva(1997) や PCATS(Kitamura & Fujii, 1998) が離散選択型の典型的な例として挙げられる一方で, TASHA(Miller & Roorda, 2003) や ADAPTS(Auld & Mohammadian, 2009) はヒューリスティクスに基づく活動生成を行いながらも, 部分的に確率モデルの採用を行なっている. 確率モデルの採用は, 計算プロセス型の課題となっている高計算コストやデータ同化の低再現性を緩和しうる拡張である. また, こうした計算方法の自由度は機械学習分野モデルの利用によっても向上している.

これを踏まえ, 各分類の計算方法について整理する.

計算プロセス型

計算プロセス型は, ある規則に基づいて生成する活動の特徴を決定する計算プロセスを組み合わせたモデルである. 活動生成の際の規則はヒューリスティクスに基づいて提案されており, 個人の意思決定を模倣する計算プロセスが構成されている.

包括的な計算プロセス型モデルとして, ALBATROSS(Arentze & Timmermans, 2004) が初めに挙げられる. ALBATROSS の活動生成手順を図 2-1 に示した. ALBATROSS では, スケジュールの枠に対して, 優先度順に活動を追加していくことで1日のスケジュールを生成する. その際, 図 2-1 のように活動の各要素(継続時間, 開始時刻, 移動手段, 活動場所)を順に, 制約に基づいて実行可能な選択集合からサンプリングすることで決定していく. 計算プロセスは重要な活動・要素から決定していくという意味決定を模倣するヒューリスティクスに基づいており, 計算プロセス型モデルを特徴付ける点である. その一方で, 実行可能な集合の作成と, 集合からのサンプリングには決定木が用いられている. 決定木は個人特性やスケジュール, 時空間制約を入力として, 活動の各要素についての選択結果を出力とする. このように, 計算プロセス型のモデルでも, 確率的な選択をモデル化するため, またはデータ同化のために確率モ

表 2.1: 各計算要素の計算方法に基づく ABM の分類

計算要素	確率モデル	ヒューリスティクス
活動パターン生成	CEMDAP, ADAPTS, Bowman & Ben-Akiva, PCATS	ALBATROSS, TASHA
継続時間, 開始時間決定	CEMDAP, Bowman & Ben-Akiva, PCATS	ALBATROSS, TASHA, ADAPTS
目的地選択	CEMDAP, Bowman & Ben-Akiva, PCATS, TASHA, ADAPTS	ALBATROSS
交通手段選択	CEMDAP, Bowman & Ben-Akiva, PCATS, TASHA, ADAPTS	ALBATROSS

デルを部分的に採用している。

計算プロセス型モデルの中で、より確率モデルを取り入れたモデルとして、TASHA(Miller & Roorda, 2003) が挙げられる。TASHA の計算プロセスを簡易的に示した図2-2の中で、活動場所と移動手段の選択において、離散選択型モデルで採用されるモデルが用いられている。活動の頻度や開始時刻、継続時間といった特徴も初めの計算プロセスで分布からサンプリングすることで生成しており、よりデータ同化を行いやすい。これら確率モデルでサンプリングされた活動をスケジュールの時間制約内に当てはめることで1日のスケジュールを生成しており、本モデル内においてヒューリスティクスは「個人のスケジュールが実現可能なものである」ことを保証するために用いられている。

離散選択型モデル

離散選択型のモデルは、個人が効用の最大化を達成する選択を行うという仮定の元、活動パターンを選択肢集合の中から生成するモデルである。

離散選択型モデルの構造は、Multinomial Logit Model(MNL モデル)をはじめとする離散選択モデルを拡張することで得られており、各個人の効用を、特徴量と推定パラメータから構成される確定項と特定の分布に従うランダム項に分解して表現する。MNL モデルはランダム項が相関のないロジット分布に従うと仮定するモデルであり、線形モデルにより選択肢 $i \in I$ の効用の確定項 V_i は式 (2.1)、選択確率 P_i は式 (2.2) として表される。Bowman & Ben-Akiva (2001) は誤差相関を加味した Nested Logit Model(NL モデル)を用いて、離散選択モデルに基づく ABS を開発した。式 (2.3) を例とする入子状の効用関数により、活動を評価する関数を

1. 活動パターン
2. 主活動の開始時刻
3. 主活動の活動場所と移動手段
4. 従属活動の開始時刻
5. 従属活動の活動場所と移動手段

の5段階の入れ子で表現した。 Λ_i は $j \in J$ に関する下位選択モデルのログサム変数であり、 $i \in I$ に関する上位選択モデルに、そのスケールパラメータ λ の大きさに応じた影響を与える。活動パターンはスケジュールを用いる計算プロセス型モデルのスケジュールに相当し、主活動の目的と従属活動の回数・目的、活動を行う場所 (home, work, other) の順列から成る。

$$V_i = \beta \cdot \mathbf{x}_i \quad (2.1)$$

$$P_i = \frac{\exp(V_i)}{\sum_{i' \in I} \exp(V_{i'})} \quad (2.2)$$

$$\begin{aligned} V_i &= \beta \cdot \mathbf{x}_i + \lambda \Lambda_i \\ \Lambda_i &= \ln \sum_{j'} \exp(V_{i,j'}) \end{aligned} \quad (2.3)$$

離散選択型のモデルでは、活動の各要素について効用を表現する関数を定義することが多いが、Kitamura & Fujii (1998) の PCATS では、スケジュール中の n 個目の活動の活動目的 X_n ・継続時間 D_n ・活動場所 L_n ・移動手段 M_n についての同時確率として定式化し、活動を生成することを目的として

いる。 k 個の活動から成る 1 日のスケジュールを生成するための確率を、式 (2.4) のように分解することで、確率の推定や活動のサンプリングを行なっている。逐次的に活動をサンプルする方法により、時空間制約の中で妥当な活動列を生成することに成功している。一方で同研究により開発された実際のモデルでは、式 (2.5) を例として同時確率を分解して考えており、最終的には NL モデルと同様に条件付き確率の計算により、同時確率の計算を置き換えている。

$$\Pr[\mathbf{X}, \mathbf{D}, \mathbf{L}, \mathbf{M}] = \prod_{i=0}^{k-1} \Pr[X_{i+1}, D_{i+1}, L_{i+1}, M_{i+1} | \tilde{X}_i, \tilde{D}_i, \tilde{L}_i, \tilde{M}_i] \quad (2.4)$$

$$\begin{aligned} & \Pr[X_{i+1}, D_{i+1}, L_{i+1}, M_{i+1} | \tilde{X}_i, \tilde{D}_i, \tilde{L}_i, \tilde{M}_i] \\ &= \Pr[X_{i+1} | \tilde{X}_i, \tilde{D}_i, \tilde{L}_i, \tilde{M}_i] \times \Pr[D_{i+1} | X_{i+1}; \tilde{X}_i, \tilde{D}_i, \tilde{L}_i, \tilde{M}_i] \\ & \times \Pr[L_{i+1} | X_{i+1}, D_{i+1}; \tilde{X}_i, \tilde{D}_i, \tilde{L}_i, \tilde{M}_i] \times \Pr[M_{i+1} | X_{i+1}, D_{i+1}, L_{i+1}; \tilde{X}_i, \tilde{D}_i, \tilde{L}_i, \tilde{M}_i] \end{aligned} \quad (2.5)$$

制約ベースモデル

制約ベースモデルは ABM の中でも初期に開発されたモデルである。本モデルは上記の 2 つのモデルとは異なり、個人のスケジュールを出力ではなく入力としている。入力として受け取った個人のスケジュールが、与えられた交通ネットワークと時空間制約の元で、実行可能であるかを判断するモデルである。近年の研究としても、活動を生成するモデルの開発ではなく、個人間相互作用の記述 (Farber et al. 2013) や選択肢集合の定義への活用 (Arentze & Timmermans, 2000) といった時空間制約の拡張が行われている。

機械学習分野モデル

近年では、機械学習分野のモデルを ABM として活用した活動生成が研究されている。計算プロセス型や離散選択型に分類されるモデルでも、AMOS(Kitamura et al., 1993) や ALBATROS(Arentze & Timmermans, 2004) など機械学習モデルを一部組み込んだ ABM は多く提案されてきた。一方、近年では機械学習モデル単体で活動生成を行うモデルの開発がされている。

2010 年代初期から今日まで、ABM での活用が続くモデルが、Bayesian Network(BN) である。BN は変数間の因果関係を非循環有効グラフ (DAG) の構造で表現する、グラフを用いた確率モデルの一種である。Ma(2015) や Ma et al.(2017) は BN のグラフ構造を推定することで、交通モード選択の際の意思決定構造を明らかにした。その後、Joubert & Waal(2020) や Waal & Joubert(2022) は BN を用いた ABM を開発し、説明可能性の高いモデルの構築を試みている。一方で、多変数・多ラベルから成る BN の構造をデータから学習することは大きな計算コストを要し、ABM 分野の研究でも限られた変数に対してのグラフ構造の学習が行われており、選択肢集合の多い目的地選択などは行われていない。

機械学習分野のモデルとして、近年利用が多い深層学習モデルの利用も行われている。Chiesa & Taraglio(2022) は Variational Auto Encoder(VAE) を用いて活動需要の生成を行なっている。こうした深層生成モデルの利用は、ABM の入力となる人口を生成するための Population Synthesis 分野でも行われており (Stanislav et al., 2019)、活動に関する観測データの増加に伴い大きな発展が期待される。

表 2.2: ABM による交通需要制御の検証

検証対象	利用モデル
シェアモビリティ	
駐車場	
混雑課金	

2.2.2 交通需要制御とモデル検証

ABM の主な開発目標の一つに、モデルを用いた交通需要制御 (TDM) が挙げられる。近年では MATSim をはじめとする開発済み ABM を用い、様々な交通施策について検証が行われている (Tajaddini et al., 2020)。近年の研究において、TDM の検討対象としている交通施策と利用された ABM を示した表 2.2 から、シェアモビリティや駐車場導入・混雑課金が多くの研究で検証されていることが分かる。利用されているモデルとしては、交通量配分モデルと接続している MATSim が利用されることが多い一方、特定の検証目的に即した他の計算プロセス型や離散選択型モデルも用いられている。

こうした ABM を用いた TDM の検証では、交通施策を導入した後の各指標の変化を計算することにより、TDM の評価を行う。同じシェアモビリティの検討でも、Cuaru et al.(2013) では導入後のシェアモビリティ利用数を検証しているのに対して、Becker et al.(2020) は異なる車両サイズによってもたらされる福祉の影響 (移動時間や一般化コスト・消費エネルギー) を評価している。また、Balac et al.(2017) はフリーフロート型のシェアモビリティの導入を MATSim により行い、利用率についての検証を行なっている。これら多様な指標の計算が可能な点は、個人の活動需要を考慮する ABM の、特に交通量配分モデルと接続することの用意な MATSim の利点である。駐車場導入でも同様に、Benenson et al.(2008) が駐車場密度による駐車場探索時間への影響を計算プロセス型のモデルで評価した一方、Waraich & Axhausen(2012) は離散選択型モデルを用いて駐車場密度や容量・料金が及ぼす自動車利用と道路混雑への影響と、多様な検証が行われている。

その一方で、検証に用いられている ABM 自体も、その精度やパラメータの感度といった項目で検証の対象となっている。Khan et al.(2022) は土地利用を組み込んだ ABM に対して、通勤開始時間・通勤距離・通勤手段・活動種類割合といった多数の予測項目について検証を行ない、モデルが TDM の検証を行うに足る精度を持つことを示した。感度については、Zhuge et al.(2019) が繰返し計算回数や計算時間幅といった MATSim のハイパーパラメータに対して検証を行っており、これらの設定によって大きく計算結果が変化することを示している。また、yang et al.(2013) は感度分析を通して、パラメータの変化 (不確実性) が ABM の出力に大きな影響を与えることを示唆した。

2.2.3 要素間相互関係

2.2.2 では、近年行われている ABM による TDM の検証について、その研究の潮流と利点を述べた。一方で、MATSim を用いて交通手段の転換を検証した Adnan et al.(2020) をはじめとして、TDM の検証を行う際の指標は一つの計算要素内で留まっている。Adnan et al.(2020) は欧州の複数都市において私有自動車の制限について検証しているが、その影響評価は他交通手段への転換や道路混雑への影響と、交通手段選択の範囲内で行われており、目的地や活動時間といった他計算要素への影響は評価されていない。

い. 現在, MATSim で用いられる需要モデルはこうした複数の計算要素間の相互作用を明示的に表現しておらず, 異なるモデルが用いられている. 各 ABM における計算要素間の相互作用について記す.

2.3 グラフィカルモデル

2.3.1 グラフィカルモデル

2.3.2 構造の学習手法